TÜBİTAK 2209-A ÜNİVERSİTE ÖĞRENCİLERİ ARAŞTIRMA PROJELERİ DESTEKLEME PROGRAMI

ARAŞTIRMA ÖNERİSİ FORMU

2025 Yılı

1. Dönem Başvurusu

A. GENEL BİLGİLER

Başvuru Sahibinin Adı Soyadı: Sinem Coşkun
Araştırma Önerisinin Başlığı: IoT Honeypot ile Makine Öğrenmesi Tabanlı Protokol Tünelleme Faaliyetlerinin ve Siber Saldırıların Tespiti
Danışmanın Adı Soyadı: Dr. Öğr. Üyesi Mehmet Ulvi Şimşek
Araştırmanın Yürütüleceği Kurum/Kuruluş: Ankara Yıldırım Beyazıt Üniversitesi

ÖZET

Özet

Bu araştırma, Raspberry Pi cihazı üzerinde yapılandırılmış siber tuzak sistemleri (honeypot) aracılığıyla Nesnelerin İnterneti (Internet of Things - IoT) ortamlarında gerçekleşen siber saldırı türlerini tespit etmek için hibrit bir analiz yöntemi geliştirmeyi amaçlamaktadır. Cowrie, Honeytrap ve Suricata yazılımları kullanılarak SSH, HTTP ve DNS protokollerine yönelik gerçek saldırı trafiği toplanacaktır. Elde edilen log verileri Message Queuing Telemetry Transport (MQTT) protokolü aracılığıyla merkezi analiz birimine aktarılacak ve SQLite veri tabanında depolanacaktır. MQTT, IoT cihazlarının küçük veri paketlerini bir aracı sunucuya gönderip oradan almak için kullanılan, düşük maliyetli ve hafif bir iletişim protokolüdür.

Toplanan veriler Python ortamında işlenerek, istatistiksel analiz yöntemleriyle entropi tabanlı tünelleme tespiti yapılacak; ayrıca makine öğrenmesi algoritmaları kullanılarak farklı saldırı örüntüleri (örneğin kaba kuvvet, port tarama, bot davranışları vb.) sınıflandırılacaktır.
Sınıflandırılan veriler ise InfluxDB adlı zaman serisi veritabanında depolanacak ve açık kaynaklı Grafana ve Apache Superset araçları ile görsel bir arayüzde sunulacaktır.

Araştırmada bağımsız değişkenler olarak oturum süresi, URI uzunluğu, karakter entropisi ve bağlantı yoğunluğu gibi trafik özellikleri; bağımlı değişken olarak ise saldırı türü veya davranış sınıfı kullanılacaktır. Tespit başarıları doğruluk oranı, yanlış pozitif oranı ve F1 skoru ile değerlendirilecektir.

Raspberry Pi cihazı Yalıtılmış Ağ Bölgesi (DMZ - Demilitarize Zone) ve misafir ağı üzerinden internete açık şekilde yapılandırılacağından, sistem gerçek saldırganlardan gelen trafiği yakalayarak yüksek etkileşimli ve sahaya yakın nitelikte veriler sağlayacaktır.

Proje sonunda geliştirilen sınıflandırma modelleri, açık kaynak kodlar ve yerli veri seti ile birlikte yayımlanarak siber güvenlik topluluğuna katkı sunacaktır. Ayrıca bu çalışmada, IoT güvenliği ve tehdit analizi alanlarında literatüre katkı yapabilecek akademik çalışma çıktısı hedeflenmektedir.

Anahtar Kelimeler: IoT Honeypot, Makine Öğrenmesi, Saldırı Sınıflandırma, Protokol Tünelleme, Siber Güvenlik

1. ARAŞTIRMA ÖNERİSİNİN BİLİMSEL NİTELİĞİ

1.1. Konunun Önemi ve Araştırma Önerisinin Bilimsel Niteliği

Günümüzde IoT cihazları, düşük donanım kaynakları [1], yetersiz güvenlik önlemleri ve yazılım açıkları [2] nedeniyle siber saldırılara açık hâle gelmiştir. Son yıllarda yapılan araştırmalar, özellikle DNS ve HTTP tünelleme tabanlı veri sızdırma ve uzaktan komut yürütme saldırılarında ciddi bir artış olduğunu göstermektedir [3].

Bu çalışmada, Raspberry Pi donanımı üzerinde yapılandırılmış honeypot sistemlerinden elde edilen gerçek saldırı verileri aracılığıyla karmaşık tünelleme faaliyetlerinin yanı sıra kaba kuvvet, port tarama ve zararlı yazılım dağıtımı gibi doğrudan sistemi hedef alan saldırıların tespiti amaçlanmaktadır. Literatürde honeypot sistemlerinin istatistiksel analiz ve makine öğrenmesi ile bütünleştirilmesinin IoT güvenliğinde güçlü bir erken uyarı mekanizması sunduğu görülmektedir [4]. Ancak, "yerli" saldırı verisi eksikliği (literatürde "sınırlı gerçek dünya testi" olarak da belirtilir [5]) ve gelişmiş protokol tünelleme tespiti konularında hâlâ sınırlı sayıda uygulama bulunmaktadır.

Bu araştırma, hem yerli honeypot verisi oluşturarak literatürdeki bu eksikliği gidermeyi hem de saldırı türlerine özel analizlerle yüksek doğrulukta tespit modelleri önermeyi hedeflemektedir. Raspberry Pi cihazının doğrudan internete açık bir şekilde yapılandırılması sayesinde, sistem kontrollü ancak gerçek saldırı trafiğine ("vahşi doğada" [6]) maruz bırakılacak ve böylece laboratuvar ortamının ötesinde, sahaya yakın koşullarda veri elde edilecektir.

Araştırma kapsamında temel soru şu şekilde formüle edilmiştir:
“IoT ortamlarında DNS ve HTTP tünelleme gibi protokol kötüye kullanımları istatistiksel analizle ne ölçüde tespit edilebilir; diğer saldırılar ise makine öğrenmesi yöntemleriyle ne kadar başarıyla sınıflandırılabilir?”
Bu doğrultuda, tünelleme tespiti için Shannon Entropisi ve Kayan Pencere (Sliding Window) analizleri; davranışsal saldırıların sınıflandırılması için ise uygun makine öğrenmesi algoritmaları kullanılacaktır.

Ayrıca, siber güvenlik alanındaki gelişmelerle birlikte platform tabanlı savunma sanayi ürünlerinde yer alan gömülü sistemlerin korunması giderek daha kritik hâle gelmiştir [7]. Bu sistemler, genellikle "bellek açısından güvenli olmayan" (memory-unsafe) dillerle yazılmış ve değiştirilmesi pratik olmayan "eski" (legacy) kod tabanlarına dayandığından [8], bu platformların dışarıdan izlenmesi kritik bir zorunluluktur. Bu bağlamda geliştirilecek honeypot ve merkezi izleme mekanizması, platform tabanlı siber güvenlik çözümlerine katkı sağlayacak, savunma teknolojileri için yerli ve uygulanabilir bir model oluşturacaktır.

Proje, Türkiye’nin 12. Kalkınma Planı (2024–2028) ve 2030 Sanayi ve Teknoloji Stratejisi kapsamında öncelikli olarak belirlenen “siber güvenlik”, “nesnelerin interneti”, “veri güvenliği” ve “yapay zekâ” temalarıyla doğrudan ilişkilidir. Bu doğrultuda çalışma, hem ulusal düzeyde güvenlik farkındalığını artıracak hem de açık kaynak tabanlı çözüm önerileriyle stratejik bir katkı sağlayacaktır.

1.2. Amaç ve Hedefler

Bu araştırmanın temel amacı, düşük donanım profiline sahip IoT cihazları üzerinde çalışan bir honeypot altyapısı kullanarak çeşitli siber saldırı türlerini istatistiksel analiz ve makine öğrenmesi teknikleriyle etkili şekilde tespit etmektir. Bu kapsamda DNS ve HTTP Protokol Tünellemesi gibi karmaşık saldırılar Shannon Entropisi ve Sliding Window yöntemleriyle analiz edilecek; kaba kuvvet saldırıları, port tarama, zararlı yazılım dağıtımı, zafiyet taramaları ve bot-insan davranış ayrımı gibi olaylar ise uygun makine öğrenmesi ve anomali tespit yöntemleriyle sınıflandırılacaktır.

Araştırma hedefleri şunlardır:

- Raspberry Pi donanımı üzerinde Cowrie, Honeytrap ve Suricata gibi farklı etkileşim seviyelerine sahip açık kaynaklı honeypot ve ağ saldırı tespit yazılımlarını kurarak gerçek saldırı verisi toplamak;
- Raspberry Pi cihazını misafir ağı ve DMZ üzerinden internete açık şekilde yapılandırarak dış kaynaklı gerçek saldırı trafiğini kaydetmek ve analiz etmek;
- Toplanan verileri MQTT protokolü ile merkezi analiz bilgisayarına aktarmak;
- Log verilerinden oturum süresi, URI yapısı, karakter entropisi, bağlantı yoğunluğu vb. anlamlı istatistiksel öznitelikler (features) çıkararak tünelleme tespitine yönelik algoritmalar geliştirmek;
- Sınıflandırmaya uygun saldırı senaryoları için etiketlenmiş veri kümesi üretmek ve makine öğrenmesi modelleri ile karşılaştırmalı analizler gerçekleştirmek;
- Analizleri bir zaman serisi veritabanında depolayıp açık kaynaklı görselleştirme araçları ile bir görsel arayüz sunmak;
- Proje sonunda yerli ve gerçek saldırı verisi ile açık kaynak kodları paylaşarak sektöre katkı sağlamak. Ayrıca literatüre katkı yapabilecek akademik araştırma çıktısı sunmak.

Bu hedefler nicel olarak değerlendirilebilecek çıktılar üretecek (ör. doğruluk oranı, yanlış pozitif oranı, F1 skoru, eğitim süresi vb.) ve öngörülen 8 aylık proje süresi içinde uygulanabilir ve sürdürülebilir bir yapı olarak planlanmıştır.

2. YÖNTEM

Bu araştırma, IoT cihazlarında yaygın olarak görülen saldırı türlerini tespit etmek amacıyla istatistiksel analiz ve makine öğrenmesi yaklaşımlarını bütünleştiren hibrit bir yöntem uygulamayı hedeflemektedir.

Bu amaçla, Raspberry Pi 4 Model B donanımı hem düşük maliyetli bir saha cihazı hem de saldırılara açık bir test ortamı olarak kullanılacaktır. Raspberry Pi cihazı, güvenli üretim ağına entegre edilmeksizin, bir misafir ağ ve DMZ yapısı altında doğrudan internete açılarak gerçek saldırı trafiğiyle temas edecek şekilde yapılandırılacaktır. Bu sayede sahaya yakın koşullarda, doğrudan dış tehditlere maruz kalan sistemlerden yüksek değerde log verisi elde edilecektir.

Saldırıların tespiti için iki temel teknik yaklaşım uygulanacaktır.

İlk yaklaşım, özellikle DNS ve HTTP protokol tünelleme davranışlarına odaklanan istatistiksel analiz yöntemleridir. Bu yöntemde Shannon Entropisi kullanılarak sorguların veya URI dizilerinin karakter çeşitliliği ölçülecek ve Sliding Window analizleriyle bu metriklerin zamana bağlı değişimleri izlenecektir. Yüksek entropi değerine sahip dizgilerin, normal (düz metin) protokol iletişimlerine ait olmama olasılığı yüksektir. Entropi değerinin belirli bir eşiği aşması, DNS veya HTTP tünelleme faaliyetlerini gösterebilir [9]. Bu analizlerle normal ağ davranışı ile gizli veri taşıma amaçlı trafik örüntüleri arasındaki farkların ortaya konması hedeflenmektedir.

İkinci yaklaşım, davranışsal saldırıların tespiti için kullanılacak makine öğrenmesi tabanlı yöntemlerdir. Bu kapsamda kaba kuvvet saldırıları, port taramaları, zararlı yazılım indirme girişimleri ve bot-insan davranış ayrımı gibi tehdit türleri, denetimli veya anomali tespitine dayalı öğrenme modelleriyle sınıflandırılacaktır [10].

Araştırmada kullanılan veriler, Raspberry Pi üzerinde kurulu üç farklı izleme sisteminden sağlanacaktır: Cowrie (SSH saldırıları için), Honeytrap (HTTP ve FTP hizmet taklitleri için) ve Suricata (genel ağ trafiğini analiz eden saldırı tespit sistemi – IDS). Bu sistemler tarafından üretilen log dosyaları, MQTT protokolü aracılığıyla merkezi bir analiz sistemine aktarılacak ve burada SQLite veri tabanında depolanacaktır [11]. Veri ön işleme ve öznitelik çıkarımı aşamaları Python programlama dili kullanılarak, Pandas ve Scikit-learn kütüphaneleri ile gerçekleştirilecektir.

Çalışmada kullanılacak başlıca bağımsız değişkenler, oturum süresi, sorgu sıklığı, karakter entropisi, URI uzunluğu, IP adresi çeşitliliği ve bağlantı yoğunluğu gibi ölçülebilir trafik özellikleridir [12]. Bağımlı değişkenler ise saldırı türü (ör. Kaba kuvvet saldırısı, tünelleme, port tarama) ve davranış sınıfı (ör. insan/bot) olarak tanımlanmıştır. Tespit başarımı değerlendirilirken üç ana ölçüt kullanılacaktır: doğruluk oranı (accuracy), yanlış pozitif oranı (false positive rate) ve F1 skoru (F1-score). F1 skoru, duyarlılık (recall) ve kesinlik (precision) metriklerinin harmonik ortalamasıdır ve özellikle dengesiz veri setlerinde doğruluk yerine daha anlamlı bir performans göstergesidir [13].

Analiz işleminin tamamlanmasından sonra oluşan çıktılar açık kaynaklı bir Zaman Serisi Veritabanı olan InfluxDB kullanılarak depolanacak, Grafana ya da Apache Superset adlı açık kaynaklı görüntüleme araçları ile de tespit başarımı çıktısı, tünelleme tespitleri ve sınıflandırılmış saldırılar zaman damgaları ile görüntülenebilecektir. Ayrıca saldırıların gerçekleştirildiği ülkeler ve bot/insan davranışları da aynı görsel arayüz ile sunulacaktır.

Bu yöntemsel yapı, projenin amaç ve hedefleriyle tam uyumludur. Tünelleme gibi entropi odaklı tespitlerin istatistiksel eşik değerleriyle modellenmesi; kaba kuvvet ve bot analizi gibi davranışsal saldırıların öğrenme tabanlı modellerle sınıflandırılması, her saldırı türü için en uygun yöntemin seçilmesini sağlamaktadır.

Ayrıca, tüm süreç proje takvimiyle doğrudan ilişkilendirilmiştir: İlk iki ay log üretimi ve veri iletim altyapısı kurulacak; sonraki iki ayda istatistiksel analiz ve öznitelik çıkarımı yapılacak; izleyen iki ayda sınıflandırma modelleri eğitilecek ve son ayda görsel arayüz oluşturulması ile tüm sonuçlar değerlendirilerek açık kaynak olarak paylaşılacaktır.

Bu yöntem hem gerçekçi bir saha kurulumu hem hibrit analiz yetkinliği hem de yerli saldırı verisinin bilimsel çıktılara dönüştürülmesi açısından güçlü bir araştırma çerçevesi sunmaktadır.

3. PROJE YÖNETİMİ

3.1 Çalışma Takvimi

ÇALIŞMA TAKVİMİ

Tarih Aralığı	Faaliyetler	Kim(ler) Tarafından Gerçekleştirileceği	Başarı Ölçütü ve Araştırmanın Başarısına Katkısı
15.10.2025 – 25.11.2025	Raspberry Pi cihazına honeypotların kurulumu ve cihazın misafir ağı/DMZ üzerinden internete güvenli biçimde açılması.	Sinem Coşkun Al-baraa Abdullah Abdullah Abdullah Al-yadumi	Cihazın 3 servisten log üretmesi ve dışarıdan saldırı alabilir hale gelmesi – %15
26.11.2025 – 20.12.2025	MQTT altyapısının kurulması ve logların veri tabanına aktarımının test edilmesi. Verilerin toplanması için SQLite şeması oluşturulması ve log türlerine göre yapılandırılması.	Sinem Coşkun Al-baraa Abdullah Abdullah Abdullah Al-yadumi	3 log kaynağının veritabanına başarıyla aktarılması – %10
21.12.2025 – 31.01.2026	Özellik mühendisliği: entropi, sorgu sıklığı, URI yapısı, oturum süresi, bağlantı yoğunluğu gibi özniteliklerin çıkarılması ve sayısallaştırılması.	Sinem Coşkun Al-baraa Abdullah Abdullah Abdullah Al-yadumi	En az 6 adet bağımsız değişkenin çıkarılması ve normalize edilmesi – %15
01.02.2026 – 10.03.2026	İstatistiksel analiz: tünelleme tespiti için Shannon entropisi + Sliding Window ile eşik tabanlı model kurulması.	Sinem Coşkun Al-baraa Abdullah Abdullah Abdullah Al-yadumi	DNS ve HTTP tünelleme için ≥ %80 doğruluk sağlayan sistemin geliştirilmesi – %15
11.03.2026 – 10.04.2026	Makine öğrenmesi: brute-force, port scanning, bot vs. insan davranış ayrımı için makine öğrenmesi modellerinin eğitilmesi .	Sinem Coşkun Al-baraa Abdullah Abdullah Abdullah Al-yadumi	Saldırılar için ≥ %80 F1 skoru sağlayan sınıflandırıcıların eğitilmesi – %20
11.04.2026 – 10.05.2026	Performans değerlendirme: doğruluk, F1 skoru, false positive oranı, görsel arayüzün oluşturulması.	Sinem Coşkun Al-baraa Abdullah Abdullah Abdullah Al-yadumi	Analiz çıktılarının grafiklerle sunulması, başarı metriklerinin karşılaştırılması – %15
11.05.2026 – 20.05.2026	Açık veri seti ve kodların GitHub'da paylaşımı; sonuçların değerlendirilmesi ve kapanış teslimleri.	Sinem Coşkun Al-baraa Abdullah Abdullah Abdullah Al-yadumi	Açık veri seti ve kodların GitHub'da paylaşımı; sonuçların değerlendirilmesi ve kapanış teslimleri – %10

3.2 Risk Yönetimi

RİSK YÖNETİMİ TABLOSU

En Önemli Riskler	Alınacak Tedbirler (B Planı)
Raspberry Pi cihazının internete açık şekilde yapılandırılması sırasında erişim sorunları yaşanması veya cihaz kaynaklarının yetersiz kalması.	Lokal test ortamı kurularak kontrollü saldırılar simüle edilir. Gerekirse Pi yerine bulut ortamı ile log üretimi sağlanır.
Gerçek saldırı trafiğinin beklenen düzeyde oluşmaması ve yeterli log verisi toplanamaması.	Açık kaynaklı saldırı log veri setleri (CTU-13, CIC-IDS 2017) projeye entegre edilerek model eğitimi ve test süreci sürdürülür. Gerçek loglarla karşılaştırmalı analiz yapılır.
Açık kaynaklı görselleştirme uygulamalarının (Grafana, Superset) sistemde çalışmaması ya da Docker ortamına entegre edilememesi.	Doğrudan Python tabanlı görselleştirme (Plotly, Streamlit) yöntemleri uygulanır.

3.3.Araştırma Olanakları

ARAŞTIRMA OLANAKLARI TABLOSU

Kuruluşta Bulunan Altyapı/Ekipman Türü, Modeli	Projede Kullanım Amacı
Raspberry Pi 4 Model B – 4 GB RAM	Honeypot sistemlerinin kurulacağı ve gerçek saldırı trafiğinin toplanacağı düşük güçlü uç cihaz (edge device) olarak kullanılacaktır.
Ev tipi modem ve yönlendirici	Raspberry Pi cihazının internete açılması için gerekli olan ağ altyapısını sağlayacaktır.
Merkez bilgisayar / sunucu	Analizlerin gerçekleştirileceği ve verilerin tutulacağı ortam olarak ana makine (host device) olarak kullanılacaktır.
Açık kaynak kodlu uygulamalar (InfluxDB, Grafana, Superset)	Saldırı analizlerinin görselleştirilmesinde ve işlenmiş verilerin saklanmasında kullanılacaktır.

4. ARAŞTIRMA ÖNERİSİNİN YAYGIN ETKİSİ

Çıktı, Etki ve Kazanımlar	Öngörülen Çıktı(lar), Etki(ler) ve Kazanım(lar)
Bilimsel/Akademik Çıktılar (Ulusal/Uluslararası Makale, Kitap Bölümü, Kitap, Bildiri vb.)	Proje sonunda en az bir ulusal veya uluslararası hakemli dergide yayınlanmak üzere bir makale veya bildiri hazırlanacaktır. Ayrıca elde edilen yerli saldırı veri seti ve analiz çıktıları, akademik araştırmalarda test verisi olarak kullanılabilecektir.

Ekonomik/Ticari/Sosyal Çıktılar (Ürün, Prototip, Patent, Faydalı Model, Tescil, Görsel/İşitsel Arşiv, Envanter/Veri Tabanı, Çalıştay, Eğitim, Bilimsel Etkinlik vb.)	Proje kapsamında oluşturulan saldırı davranışlarına ait loglar, öznitelik tabanlı veri seti ve geliştirilen analiz kodları, Türkçe dokümantasyon eşliğinde GitHub platformu üzerinden açık kaynak olarak yayımlanacak; böylece diğer araştırmacılar için temel oluşturabilecek teknik bir çerçeve sunulacaktır.
Yeni Proje(ler) Oluşturmasına Yönelik Çıktılar (Ulusal/Uluslararası Yeni Proje vb.)	Proje çıktıları, üniversite-sanayi iş birliği kapsamında ulusal siber güvenlik projelerine genişletilebilir. Ayrıca çeşitli hibe programları ve yarışmalar için zemin oluşturulabilir.

5. BELİRTMEK İSTEDİĞİNİZ DİĞER KONULAR

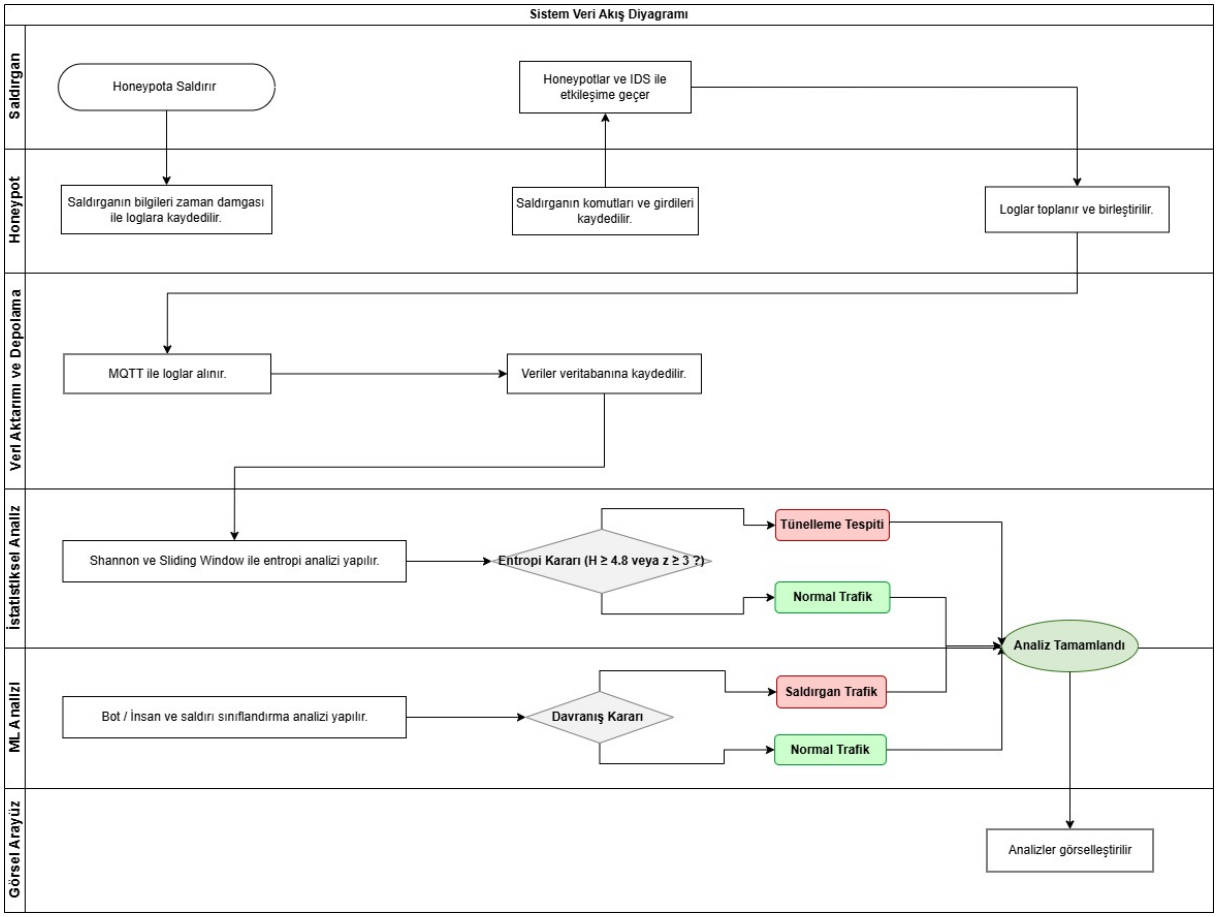

Şekil 1 Sistemin Veri Akış Şeması

6. EKLER

EK-1: KAYNAKLAR

[1] F. Al-Turjman, et al., "Federated Learning for IoT Security and Privacy," Future Internet, vol. 17, no. 1, 2025. [Online]. Available: https://www.mdpi.com/1999-5903/17/1/30

[2] M. Kaur and S. Singh, "IoT Network Security Threats and Countermeasures," Computers, vol. 14, no. 2, 2025. [Online]. Available: https://www.mdpi.com/2073-431X/14/2/61

[3] R. N. Rao, "AI-Driven Detection of IoT Attacks using Honeypot Data," PubMed Central (PMC), 2024. [Online]. Available: https://pmc.ncbi.nlm.nih.gov/articles/PMC10818527/

[4] A. Ahmed et al., "Securing Smart Cities through Machine Learning: A Honeypot-Driven Approach to Attack Detection," IET Smart Cities, 2024. [Online]. Available: https://www.open-access.bcu.ac.uk/15567/1/IET%20Smart%20Cities%20-%202024%20-%20Ahmed%20-%20Securing%20smart%20cities%20through%20machine%20learning%20%20A%20honeypot%E2%80%90driven%20approach%20to%20attack-2.pdf

[5] R. D. Venkat Goundla, "Analysis of IoT Honeypots for Network Security," Applied Sciences, vol. 15, no. 10, 2025. [Online]. Available: https://www.mdpi.com/2076-3417/15/10/5251

[6] V. G. Goundla, "Optimizing Internet of Things Honeypots with Machine Learning: A Real-World Study," Norma NCI Repository, 2024. [Online]. Available: https://norma.ncirl.ie/8173/1/venkatgoudgoundla.pdf

[7] D. Ivanov, "Securing Military Embedded Systems: Three Challenges," Military Embedded Systems, 2024. [Online]. Available: https://militaryembedded.com/cyber/cybersecurity/guest-blog-securing-military-embedded-systems-three-challenges

[8] Quest Defense, "Evolution of Embedded Systems in Aerospace & Defense: From 8-bit to AI-driven Solutions," Quest Defense Insights, 2024. [Online]. Available: https://www.quest-defense.com/insights/thought-leadership/evolution-of-embedded-systems-in-aerospace-defense-from-8-bit-to-ai-driven-solutions/

[9] Huang, X., & Huo, Y. (2023). A Comprehensive Review of Tunnel Detection on Multilayer Protocols: From Traditional to Machine Learning Approaches. Applied Sciences, 13(3), 1974.

[10] Alve. (2025). Smart IoT Security: Lightweight Machine Learning Techniques for Multi-Class Attack Detection in IoT Networks. arXiv. https://arxiv.org/abs/2502.04057

[11] Bhandari, A., Lyth, T., Shalaginov, A., & Grønli, T.-M. (2023). Distributed Deep Neural-Network-Based Middleware for Cyber-Attacks Detection in Smart IoT Ecosystem: A Novel Framework and Performance Evaluation Approach. Electronics, 12(2), 298.

[12] Salat, T., Davis, J., & Khan, M. (2023). DNS Tunnelling, Exfiltration and Detection over Cloud Environments. Sensors, 23(5), 2760.

[13] Üstebay, F. (2025). Enhancing Zero-Day Attack Detection in IoT Networks via Isolation. Electrica, 25(2), 1–8.